# 微博峰值应对系统DCP在混合云方面架构实践



# Geekbang》. 极客邦科技

整合全球最优质学习资源,帮助技术人和企业成长 Growing Technicians, Growing Companies



技术媒体





高端技术人员 学习型社交网络





实践驱动的 IT职业学习和服务平台





一线专家驱动的 企业培训服务



#### 旧金山 伦敦 北京 圣保罗 东京 纽约 上海 San Francisco London Beijing Sao Paulo Tokyo New York Shanghai



2016年4月21-23日 | 北京:国际会议中心

主办方 **Geekbang**》. **InfoQ**®

**优惠(截至12月27日)** 现在报名,节省2040元/张,团购享受更多优惠



#### 自我介绍

微博平台技术经理

DCP项目

微博关系架构

Feed高可用架构实现



#### 分享主要内容

- 一、DCP整体介绍
- 二、弹性集群
- 三、弹性调度
- 四、服务发现





# Part 1

DCP整体介绍

#### DCP架构演进

#### 容器化

- 无状态业务
- 在线集群

#### **DCP**

#### 公有云

- 弹性调度
- 服务发现
- 微服务化

#### 混合云

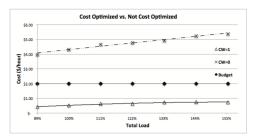
- 整合离线计算 集群
- 跨云部署
- 多种调度实现整合

#### DCP项目出发点

• 可伸缩的业务利用公有云

• 混合云调度理论能节省6

倍成本

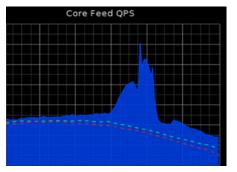


- Inadianapa Carlo
- 拉通多语言环境
- 发挥运维规模化优势



运维标 业务快 准化 速迭代

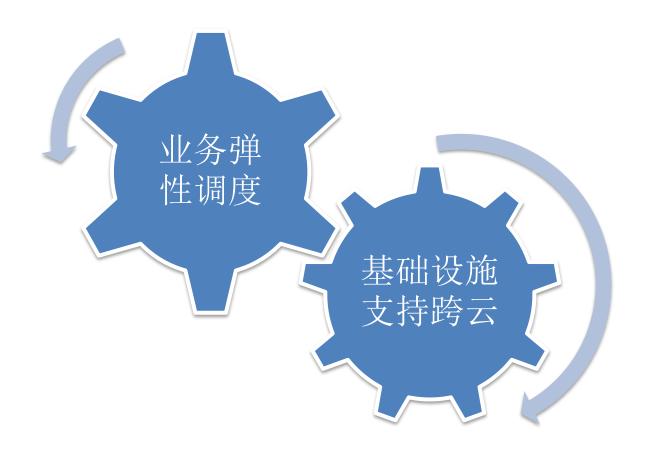
- 快速扩容
- 及时回收



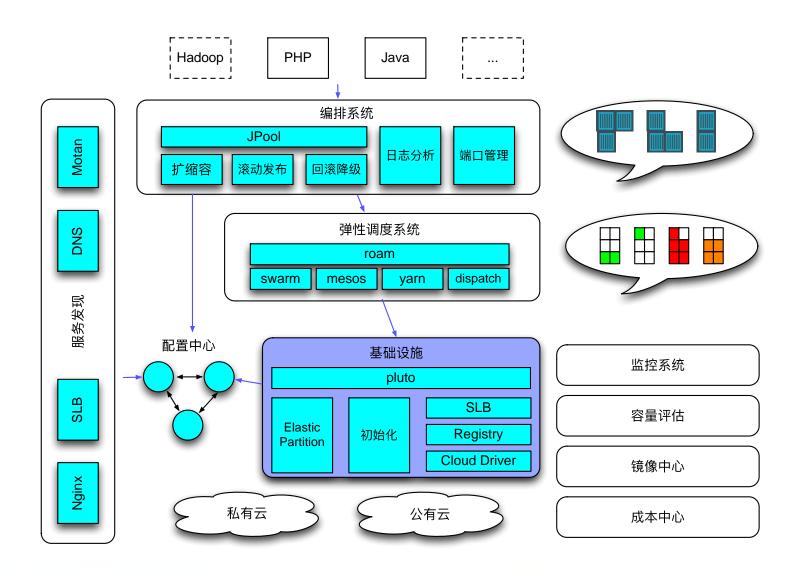


· 享受标准化基础 设施红利

### DCP主要思路



#### DCP整体结构

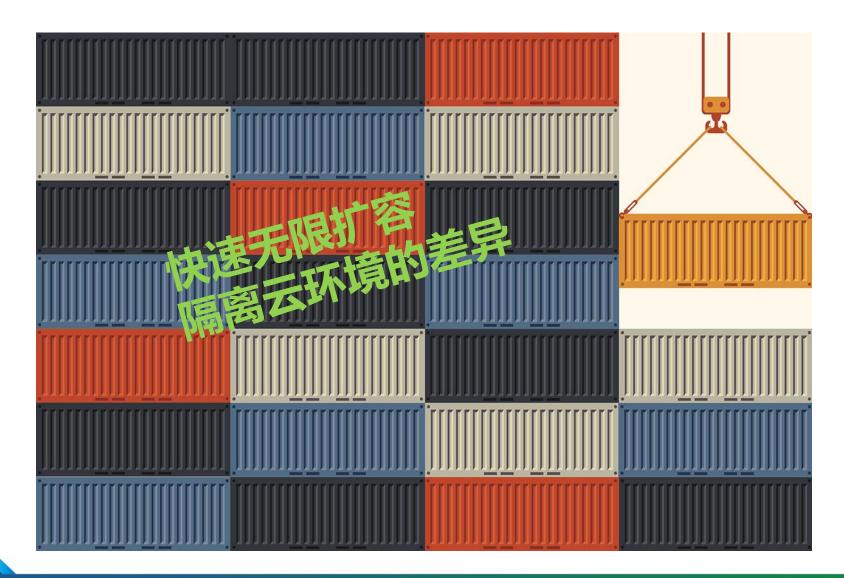




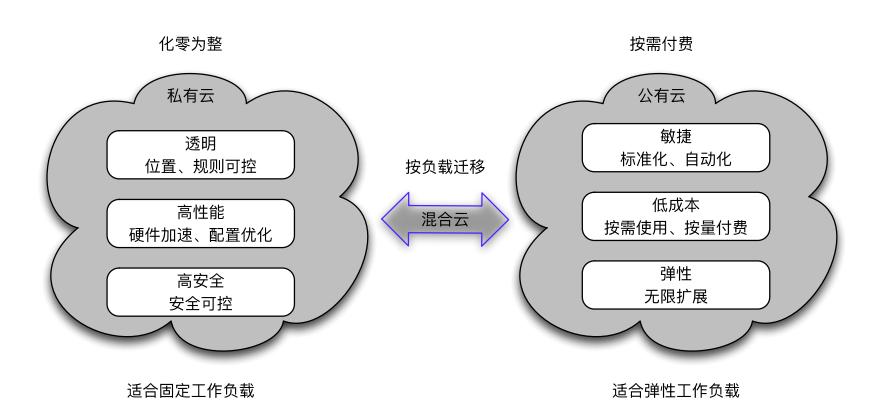
# Part 2

弹性集群

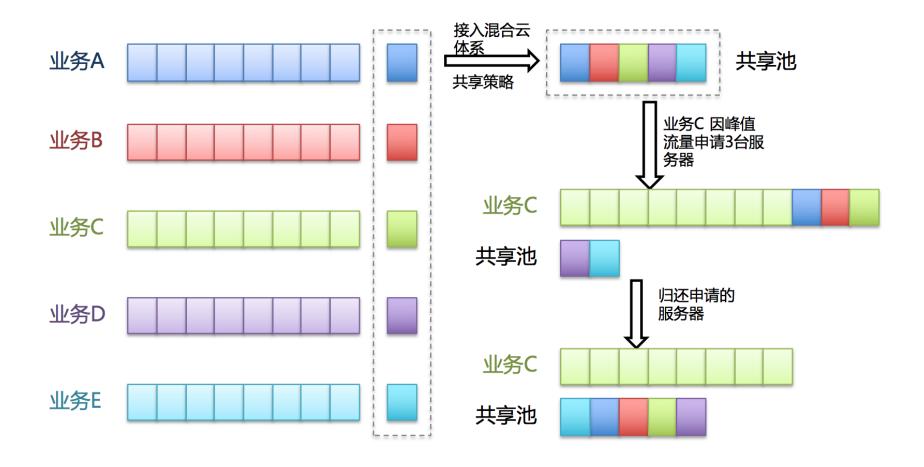
## 扩!扩!扩!



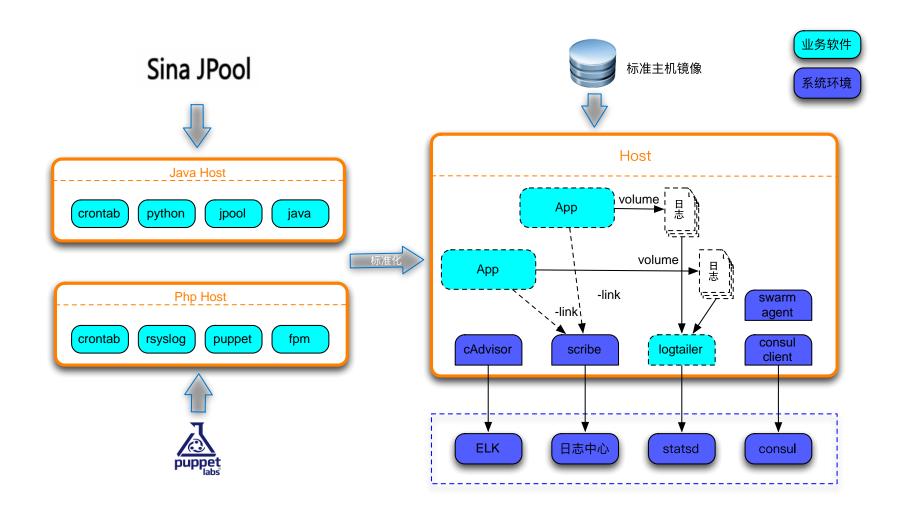
#### DCP基础设施弹性策略



#### 私有"云"化零为整



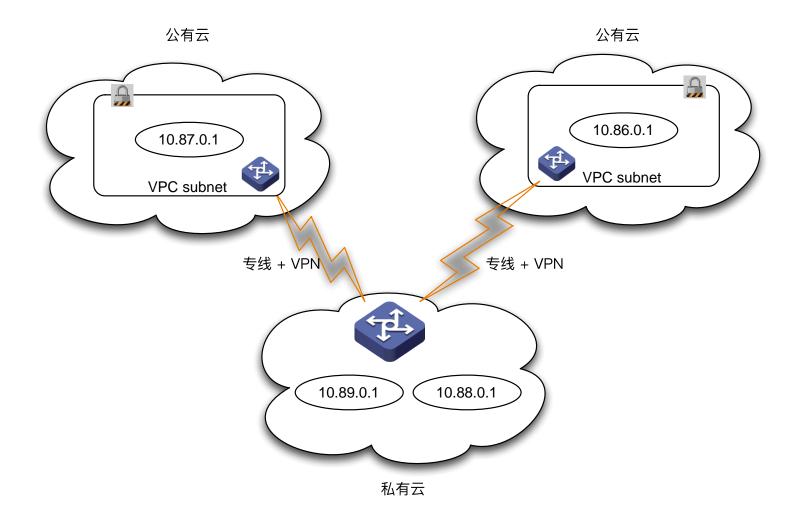
#### 打破差异 - 标准化运行环境



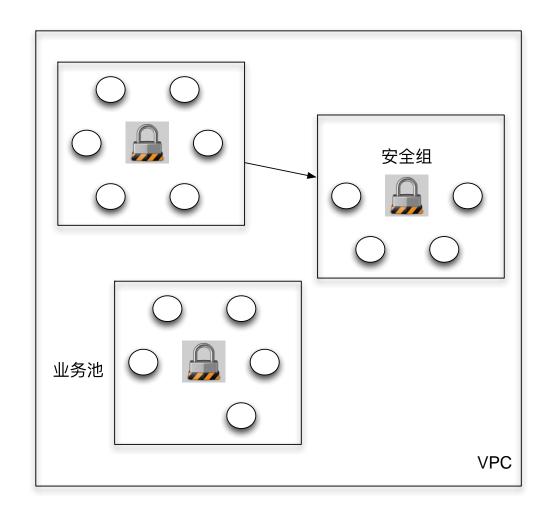
## 基础环境软件版本

Java		php	
cAdvisor 0.7.1.fix			
Mesos 0.25			
Swarm 1.0.0			
Consul 0.5.2			
Docker 1.6.2	Registry v2	Daemon Wrapper	Registry v1
devicemapper-direct-lvm		Docker 1.3.2	
		devicemapper-loop-lvm	
CentOS 7.1.1503/3.10.0-229.el7.x86_64		CentOS 6.6/2.6.32	

## DCP网络高可用



## DCP安全隔离

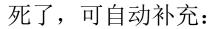


#### 高可用问题 - 不怕死就怕慢

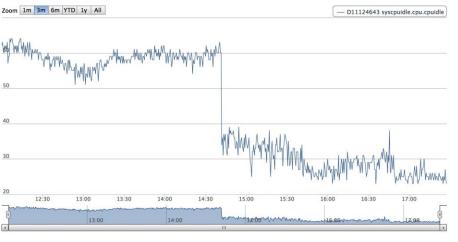
```
90 90 55 48 89 e5 53 48 89 fb 48 83 ec 08 48 8b 47 08 <4c> 8b 00 4c 39 c7 75 39
 48 8b 03 4c 8b 40 08 4c 39 c3 75 4c 48
   [<fffffffff81294ee0>] list del+0×10/0×a0
RSP <ffff8801e9f87dc8>
 --[ end trace 5a299f957d120f7e ]---
Kernel panic - not syncing: Fatal exception
Pid: 1553, comm: docker Tainted: G
                                                                    2.6.32-431.23.3
el6.x86_64 #1
Call Trace:
 [\langle fffffffff815284fc \rangle] ? panic+0\timesa7/0\times16f
 [<fffffffff8152c824>] ? oops_end+0xe4/0x100
 [<fffffffff81010e0b>] ? die+0x5b/0x90
  <fffffffff8152c302>1 ? do_general_protection+0×152/0×160
    ffffffff8152bad5>1 ? general_protection+0x25/0x30
 [<ffffffffff81294ee0>] ? list_del+0x10/0xa0
 [\langle fffffffff810c9e12\rangle]? cgroup_event_wake+0x42/0x70
 [<fffffffff810546b9>] ? __wake_up_common+0x59/0x90
  <fffffffff81058bc8>1 ? __wake_up+0x48/0x70
  (ffffffffff811d56ed>] ? eventfd_release+0x2d/0x40
 [<fffffffff8118a715>] ? __fput+0xf5/0x210
  <fffffffff8118a855>] ? fput+0x25/0x30
   fffffffff81185a9d>l ? filp_close+0x5d/0x90
 [<fffffffff81185b75>] ? sys_close+0xa5/0x100
 [<fffffffff8100b072>] ? system_call_fastpath+0x16/0x1b
```

#### 慢了!怎么办?

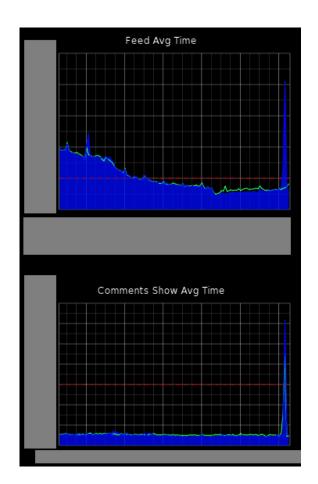
- 有可能是业务慢
- 有可能是机器慢
- 有可能是网络慢



- 1. 根据镜像新建设备
- 2. 调度系统重建业务容器



#### 监控从全网平均到单机全覆盖



往往系能恶化是由于单机问题引起 如何快速定位有问题的机器?

#### 单机性能恶化



服务所在位置:/data1/friendship \_\_\_\_\_

System Load:0.01 Tomcat Load:0.01 Swap使用比例:0.42% 非堆使用比例:70.28%

10秒内HTTP请求次数:508

10s内错误响应次数:332 10s内超过500ms的响应次数:1

Tomcat繁忙线程比例:0.0% 系统当前停顿时间:0ms 系统10分钟内停顿次数:0 系统10分钟内YGC次数:1 GC后OId区使用比例:27.66% GC后Old区减少比例:-0.56%

DirectBuffer数量:1263

DirectBuffer池总的容量:52.589467MB DirectBuffer池使用的容量:52.589467MB 业务容器级报警

#### 高可用问题-公有云单机性能瓶颈

#### 单机性能问题



#### 测试CPU:

sysbench --test=cpu --cpu-max-prime=10000 run sysbench --test=threads --num-threads=64 --thread-yields=2000 --thread-locks=2 run

#### 测试磁盘:

fio -direct=1 -iodepth=64 -rw=randwrite -ioengine=libaio -bs=16k -size=10G -numjobs=1 -runtime=1000 -group\_reporting -name=/path/testfile

#### 测试内存:

mbw -q -n 10 256

#### 测试带宽:

netperf -H host -l second -t [TCP\_STREAM|UDP\_STREAM|TCP\_RR|TCP\_CRR|UDP\_RR] -s localBufferSize -S remoteBufferSize -m localPackageSize -M remotePackageSize -D TCP NODELAY

#### 测试业务

#### 高可用问题 - 自由也是责任

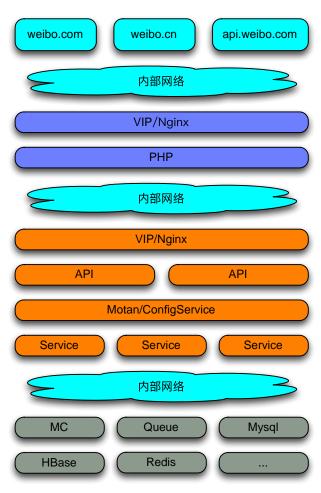




# Part 3

弹性调度

#### 弹性调度的挑战 - 重型服务调度难



内网服务架构

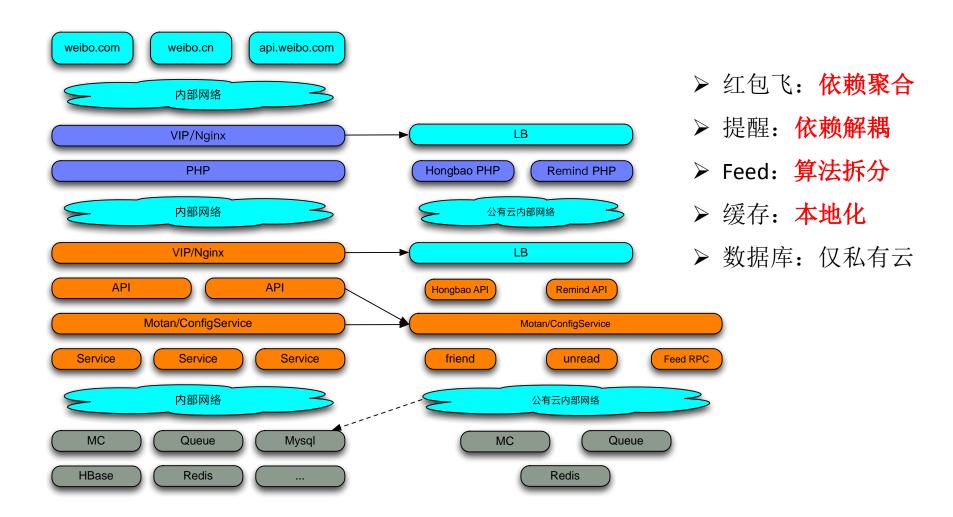


- > 依赖关系复杂
- > 跨云专线带宽是稀缺资源

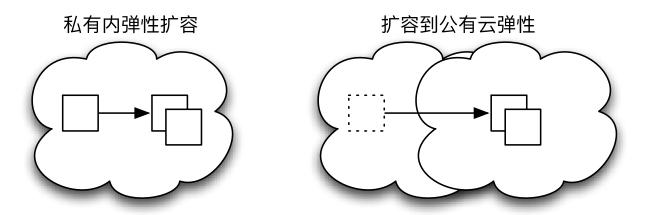


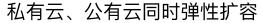
- 微服务化,尽量在一个云上 完成处理,减少穿透
- 2/8原则,往往一个服务里只有20%的部分需要弹性,而且能解决80%问题

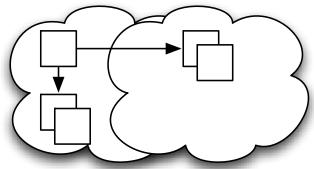
#### 微业务化 - 以最少的资源实现最大的弹性



## 混合云弹性扩容方式







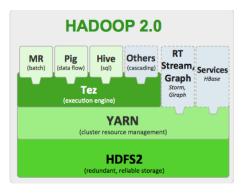
#### 业界:从Static Partitioning到Elastic Sharing









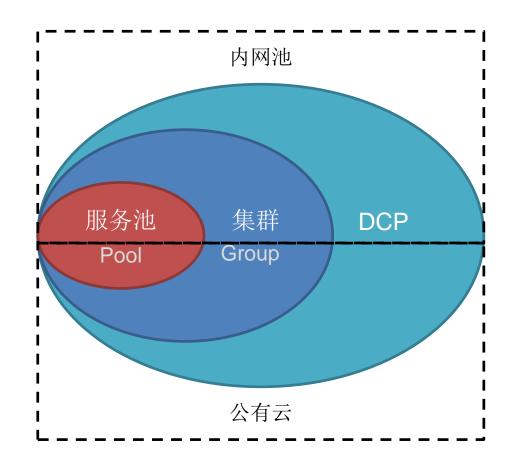




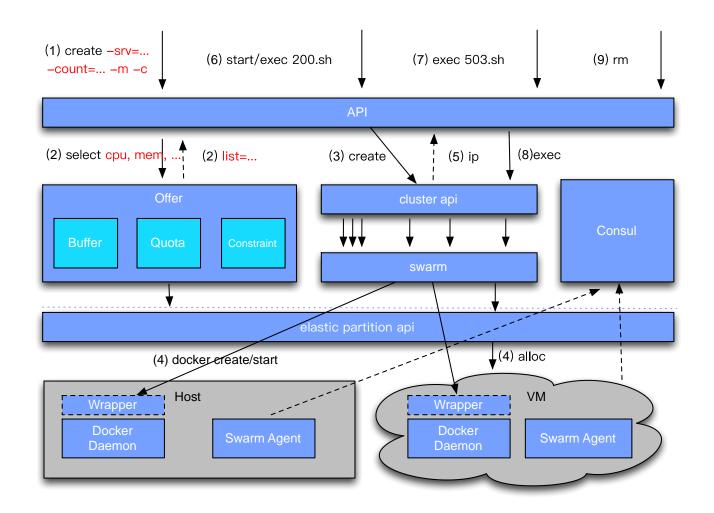
## DCP弹性调实现 – Elastic Partition

**JPool** 动态应用 数据分析平台 ...平台 监控报警 弹性范围 业务池 业务上线 业务池 任务发布 流量迁移 业务发布系统 上线/回滚 上线/回滚 资源限制 实例维护 自我恢复 调度框架 VM容器 集群容器 业务容器 业务容器 服务注册与发现 自定义调度 Scheduler API mesos swarm yarn Elastic Partition API: 收集设备的资源情况 业务集群弹性能力 hadoop Java php cloud

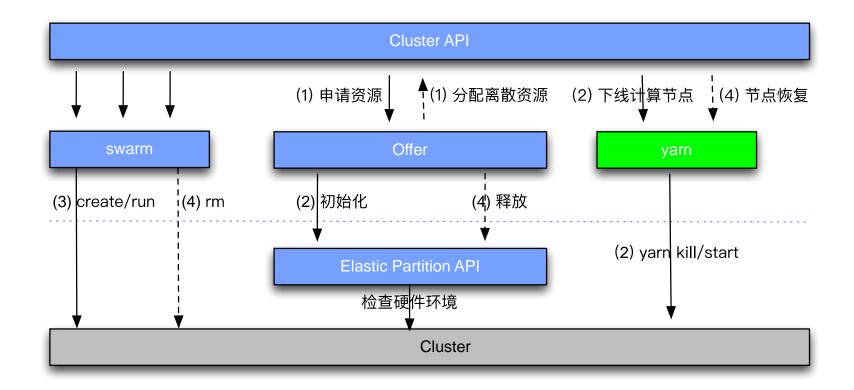
## Partition分布 - 业务视角



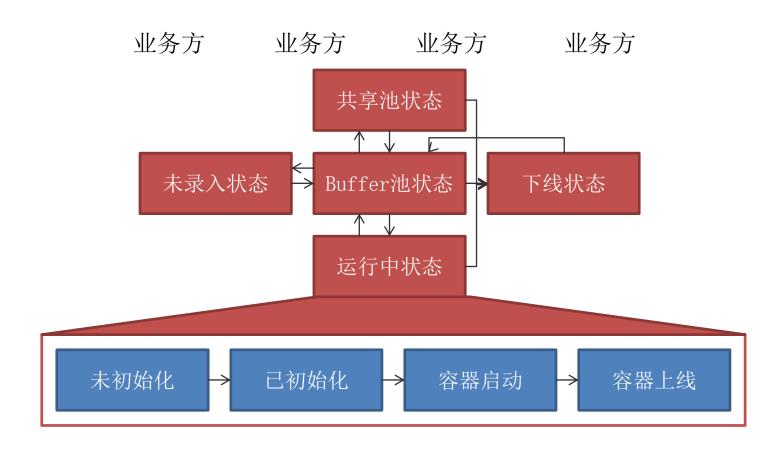
## DCP弹性调度过程



## DCP弹性调度 - 不同partition间调度



#### 生命周期管理



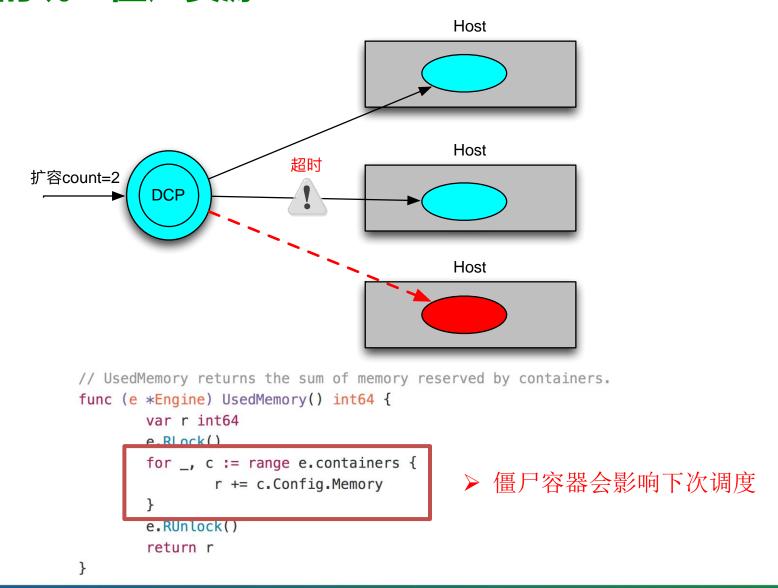
#### 扩容容易缩容难

- > 流量低峰时如何安全缩容
  - ▶ 下线节点,引发故障!
  - ▶ 下多少是安全的?
  - ▶ 人是不靠谱的!

#### 容量评估系统



#### 遇到的坑 - 僵尸资源



#### 遇到的坑 - 开源软件的缺陷

#### 全局锁导致批量创建容器效率极低

```
func (c *Cluster) createContainer(config *cluster.ContainerConfig, nam
        c.scheduler.Lock()
        defer c.scheduler.Unlock()
                             V0.4.0
func (c *Cluster) createContainer(config *cluster.ContainerConfig, nam
        c.scheduler.Lock()
        c.scheduler.Unlock()
        container, err := engine.Create(config, name, true)
                           V1.0.0.rc1
```

#### 遇到的坑 - 版本兼容陷阱

```
const (
    // Force-refresh the state of the engine this often.
    stateRefreshPeriod = 30 * time.Second

// Timeout for requests sent out to the engine.
    requestTimeout = 10 * time.Second

// Minimum docker engine version supported by swarm.
    minSupportedVersion = version.Version("1.6.0")
)
```

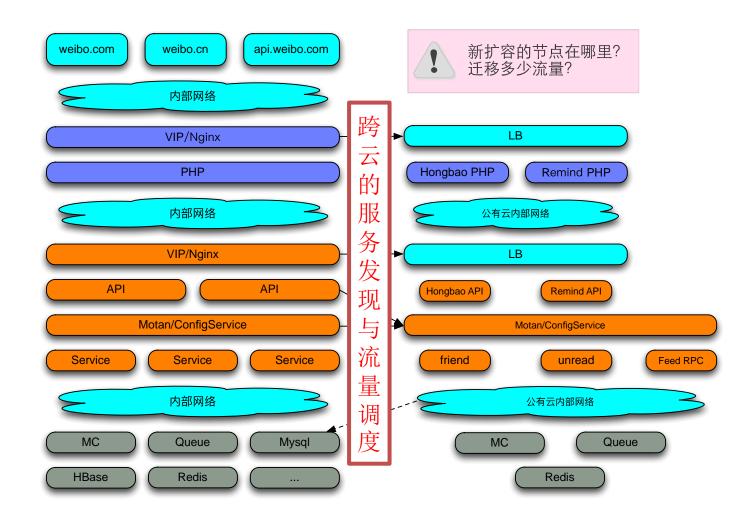
- Working on Docker Daemon Wrapper for 1.3.2
  - ➤ 兼容Name, Total Memory, CPUs, Labels



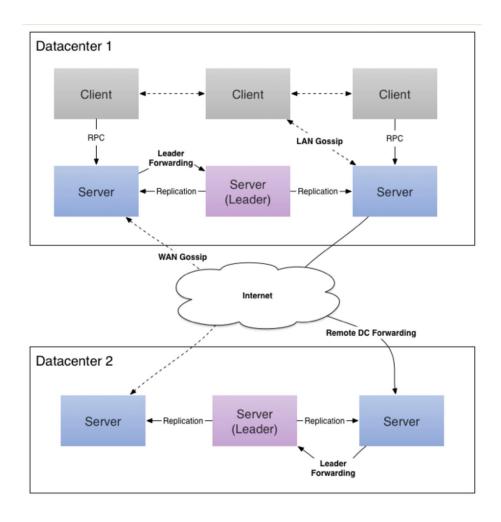
# Part 4

服务发现

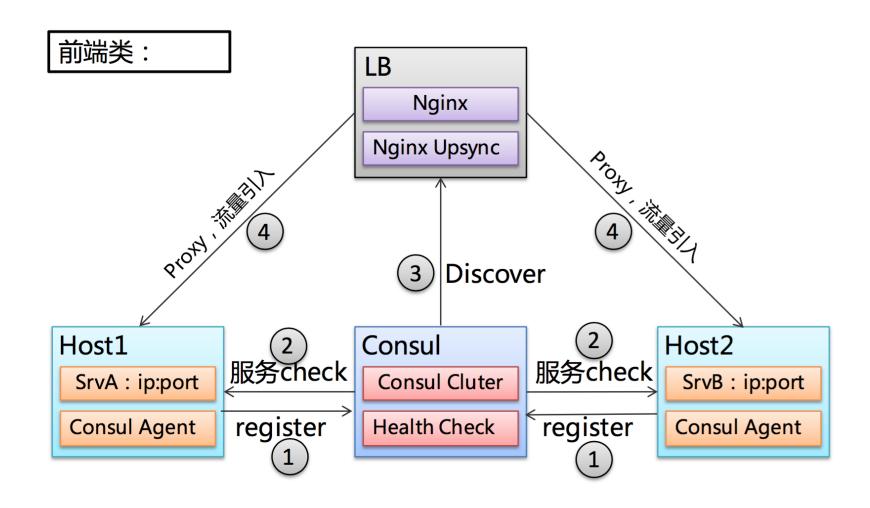
## 流量要快速、安全的切到弹性节点



# 基于Consul实现跨云服务发现



## 7层服务发现



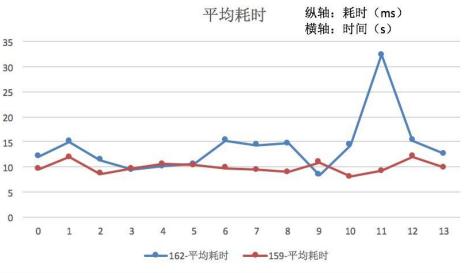
# 需要注意的问题 – Reload损耗

- > 开源解决方案大多利用Nginx的Reload机制
- 性能损耗情况:

▶ 请求量:普通reload会导致吞吐量下降10%

▶ 平均耗时:差异不大,稍有优势



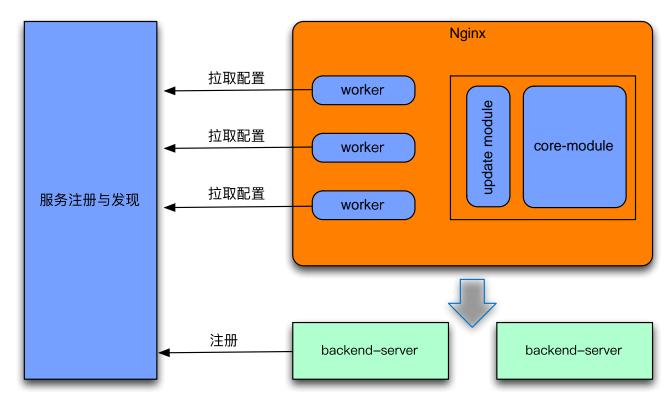


# Nginx Reload可能的损耗点

- ▶ fork 新的进程的开销(内存,新的work 进程的初始化);
- ➤ 基于client、backend 的所有的长链接需要重新的创建;
- 旧的work 进程需要频繁的检索connection 的链接数据结构,判断是否所有的处理请求已经处理完;
  - ▶ 参考: https://github.com/alibaba/tengine/issues/595 ; 这是一个普遍问题 , 1.9.0之后的版本做了一些优化 , 但是只是优化 ;
- ➢ 新旧work 进程对cpu 的争夺;
- ➢ 商业的Nginx Plus提供了API

# 微博的方案 - Nginx Upsync

- ➤ Nginx Plus的开源版
- ➤ 支持基于Consul自动服务发现
- ➤ 开源: https://github.com/weibocom/nginx-upsync-module

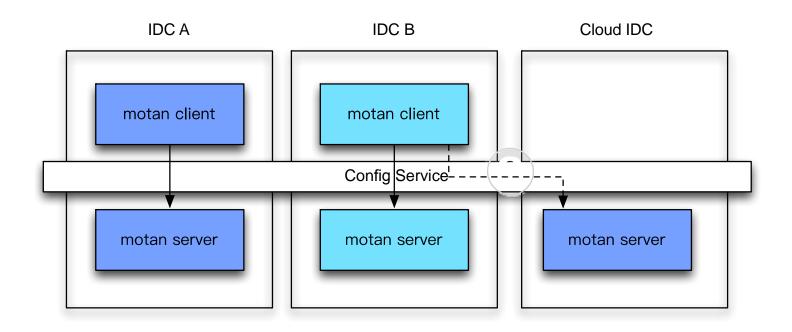


# Nginx Upsync - 自动适配后端处理能力

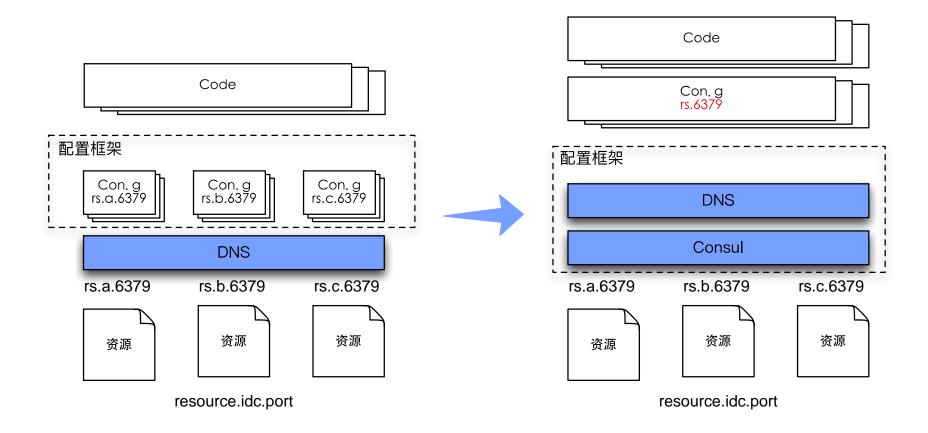
- 弹性节点的处理能力不对等
  - ➤ server 10.xx.xx.xx:xxxx max\_fails=0 fail\_timeout=30s weight=20; #同样的权 重导致单点性能恶化
- ▶ 节点注册计算能力
  - 所有节点默认权重是20;
  - 公有云有20%性能损耗,权重=16;

#### Motan RPC服务发现

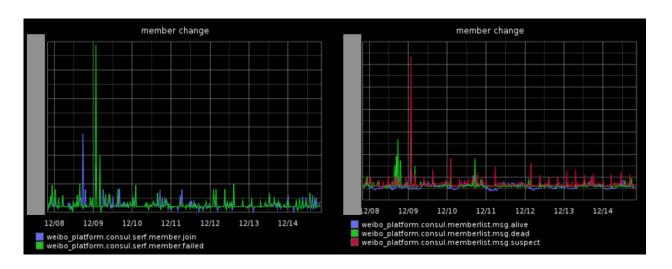
- ➤ Motan流量路由模型优先匹配单IDC
  - ▶ IDC间切换一般仅在故障处理时采用
- ➤ 新版Motan已支持按流量权重配置定向路由



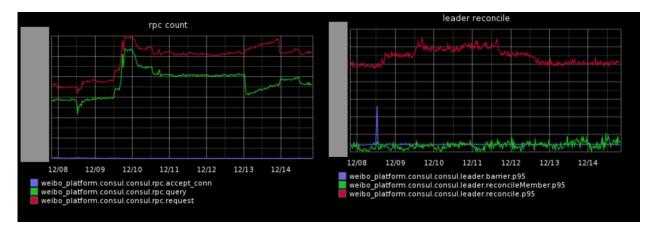
# DNS服务发现



#### Consul集群监控



▶ 节点状态抖动频率



➤ QPS及耗时



# Part 5

总结

## 微博DCP功能点







业	红包飞	MAPI	广告	有信	Feed
务方	用户	通讯	平台架构		
P A	Swarm	Docker 调度策略	Mesos 调度管理	容量评估	Docker Register
A S	Java对接		离线对接		Docker 镜像市场
I A	Buffer池 调度管理	成本核算	ECS管理	SLB等 管理	Consul 工具管理
A S	四七层 解决方案	专线保障	公有云 流量管理	审批流程	Docker 版本管理
基 础	软件安装	工程框架	安全保障	账户体系	Docker
框架	监控体系	DNS	PPoo1	公有云 Yum/日志	工具体系

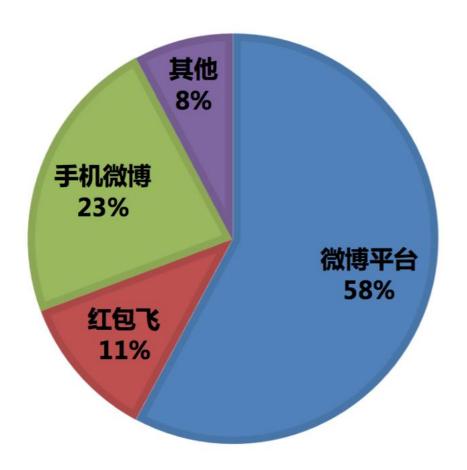
## 微博DCP进展

▶ 项目进展

▶ 项目上线:2015年10月

▶ 容器数:3000+

- ➤ 双十一
  - ▶ 单日10次扩缩容
  - ▶ 单次操作时间<5分钟



# Thanks!

